快速预览简介页

— 8×8 PE 阵列 – 5 级流水线张量计算单元

一、 实现功能

- ✓ **3种维度：** 支持m16n16k16、m32n8k16、m8n32k16 3种矩阵维度 乘加运算
- ✓ **7种精度：** 支持 INT4、INT8、INT32、FP16、FP32、FP64、BF16 7种数据精度 格式运算
- ✓ **硬件资源复用：** 8×8PE阵列；PE多精度共用乘加法器；FP16、FP32共用浮点乘法单元
- ✓ **支持混合精度计算：** 3种模式 ①INT4/INT8 + INT32；②FP16 + FP32 + FP64；③BF16 + FP32 [包含数据精度、混合计算模式扩展]
- ✓ **支持计算结果溢出处理：** 参考IEEE整数、浮点数算数标准；支持非规格数处理
- ✓ **性能指标：** 综合频率214.6MHz、面积LUT用量8%、功耗3.663W、理论算力值27.47GOPS
- ✓ **4：2稀疏：** 综合频率206.53MHz、面积LUT用量7%、功耗2.798W（动态功耗缩减为原来1/4）、理论算力值27.47GOPS
- ✓ **支持Tile - wise稀疏 & 权重剪枝 + [FP32转BF16]量化：** 动态功耗降低至0.276W

二、 性能指标

类别	指标
综合频率	214.6MHz
面积	LUT 使用率 8%、FF 使用率 2%、IO 使用率 22%
功耗	总功耗 3.663W（动态功耗 1.117W、静态功耗 2.486W）
存储带宽	3.2GB/s
算力	理论算力：27.47GOPS；实际算力：12.3GOPS
能效比	理论能效比：7.50GOPS / W；仿真能效比：3.36GOPS/W
计算延迟	163.1ns

三、核心验证图表

<table>
<tr><td>1. 模块整体结构图</td><td> 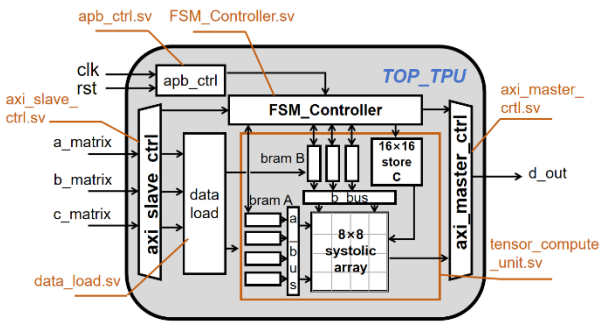
</td></tr>
<tr><td>2. 计算阵列结构图</td><td> 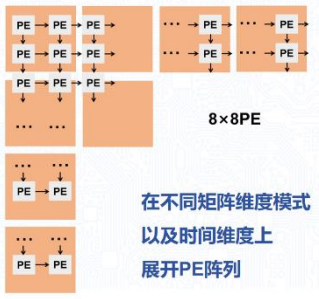
</td></tr>
<tr><td>3. 数据传输通道结构图</td><td> 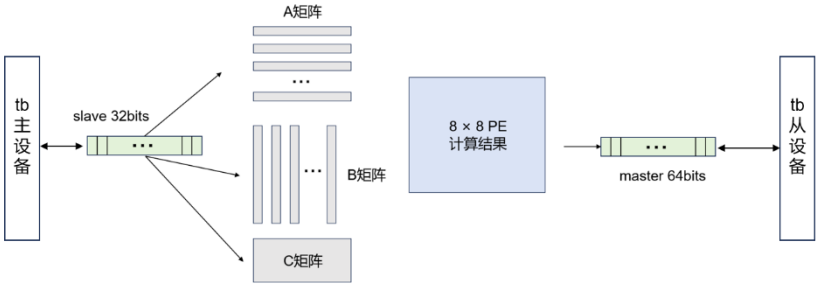
</td></tr>
<tr><td>4. FPGA 验证
综合频率
资源占用
功耗截图</td><td>
<table>
<tr><th>Resource</th><th>Utilization</th><th>Available</th><th>Utilization %</th></tr>
<tr><td>LUT</td><td>92722</td><td>1182240</td><td>7.84</td></tr>
<tr><td>FF</td><td>46307</td><td>2364480</td><td>1.96</td></tr>
<tr><td>IO</td><td>187</td><td>832</td><td>22.48</td></tr>
</table>
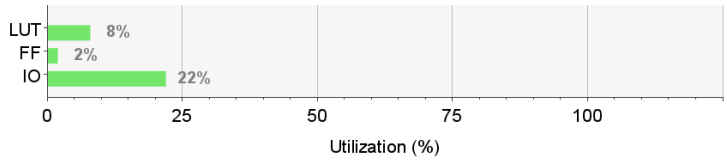
</td></tr>
</table>

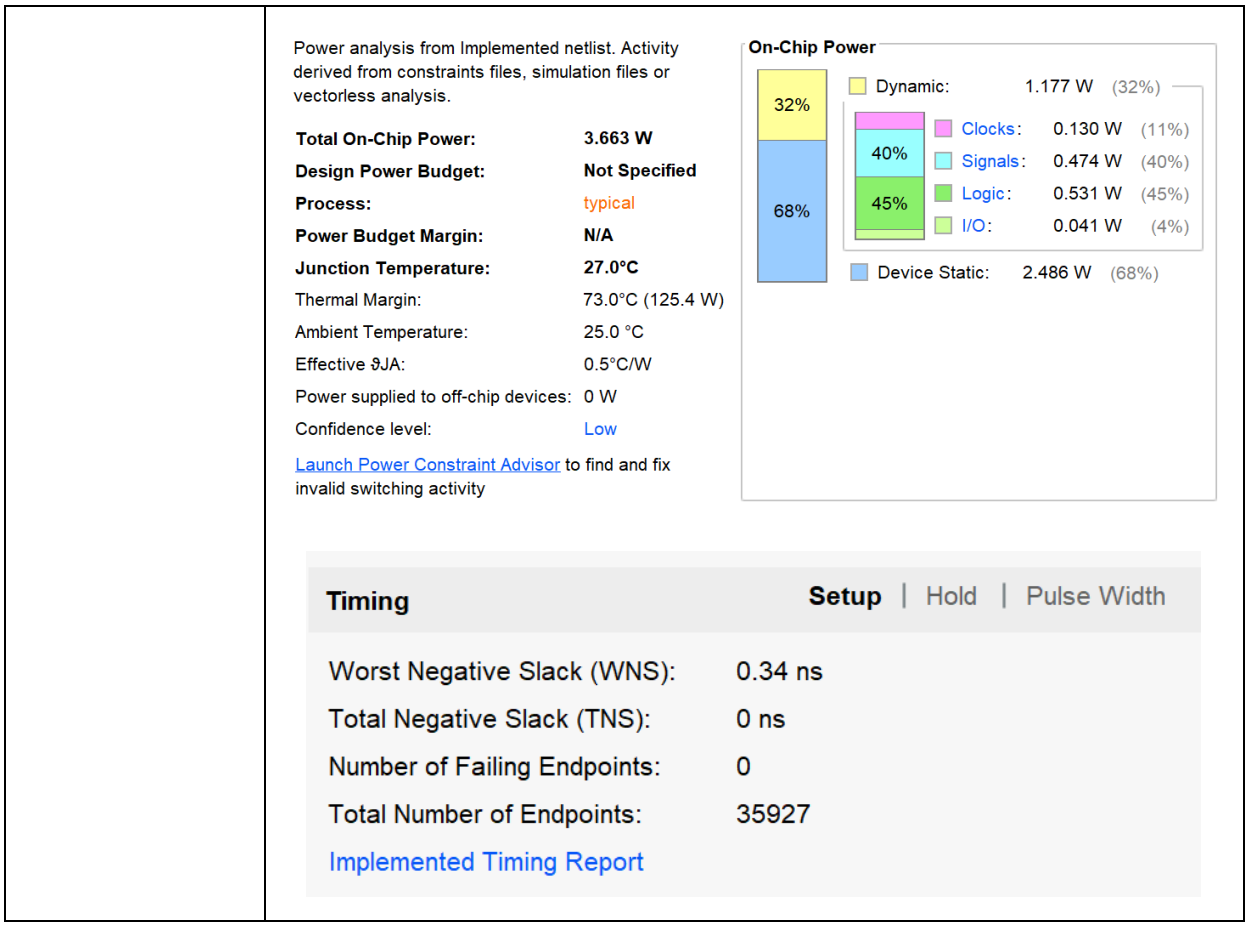

四、项目不足及改进方向

时序裕度余量较少，可能不能稳定工作在 200M 时钟频率下。未来我们将把工作中心放在优化时序性能以及提升能效比上，以及做上板实物验证测试。