快速预览简介页

— 8×8 PE 阵列 - 5 级流水线张量计算单元

一、 实现功能

- ✓ **3种维度：支持m16n16k16、m32n8k16、m8n32k16 3种矩阵维度 乘加运算**
- ✓ **7种精度：支持 INT4、INT8、INT32、FP16、FP32、FP64、BF16 7种数据精度 格式运算**
- ✓ **硬件资源复用：8×8PE阵列；PE多精度共用乘加法器；FP16、FP32共用浮点乘法单元**
- ✓ **支持混合精度计算：3种模式 ①INT4/INT8 + INT32；②FP16 + FP32 + FP64；③BF16 + FP32 [包含数据精度、混合计算模式扩展]**
- ✓ **支持计算结果溢出处理：参考IEEE整数、浮点数算数标准；支持非规格数处理**
- ✓ **性能指标：综合频率214.6MHz、面积LUT用量8%、功耗3.663W、理论算力值27.47GOPS**
- ✓ **4：2稀疏：综合频率206.53MHz、面积LUT用量7%、功耗2.798W（动态功耗缩减为原来1/4）、理论算力值27.47GOPS**
- ✓ **支持Tile - wise稀疏 & 权重剪枝 + [FP32转BF16]量化：动态功耗降低至0.276W**

二、 性能指标

类别	指标
综合频率	214.6MHz
面积	LUT 使用率 8%、FF 使用率 2%、IO 使用率 22%
功耗	总功耗 3.663W（动态功耗 1.117W、静态功耗 2.486W）
存储带宽	3.2GB/s
算力	理论算力：27.47GOPS；实际算力：12.3GOPS
能效比	理论能效比：7.50GOPS / W；仿真能效比：3.36GOPS/W
计算延迟	163.1ns

三、核心验证图表

1. 模块整体结构图	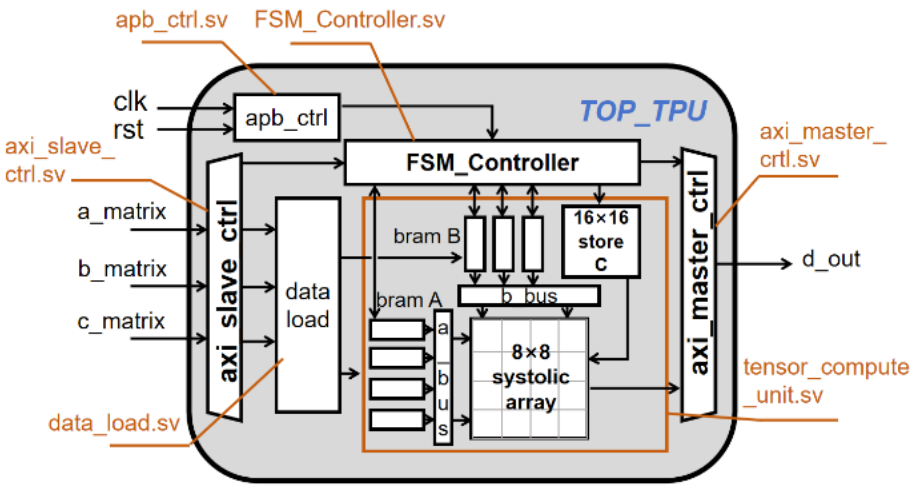
2. 计算阵列结构图	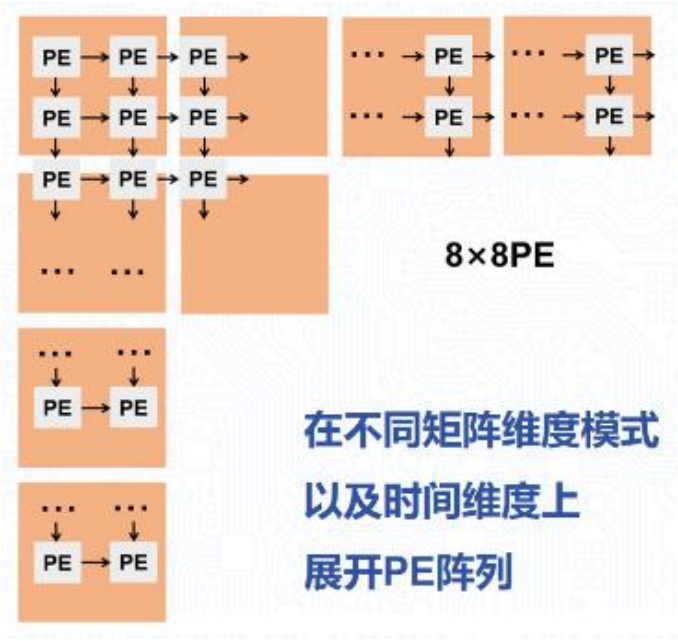
3. 数据传输通道结构图	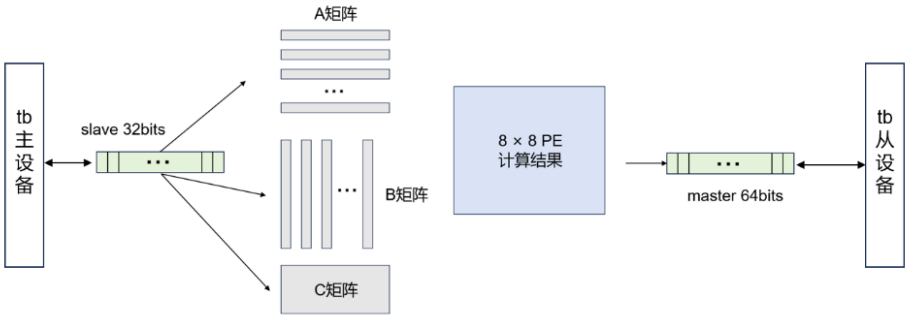

4. FPGA 验证

综合频率

资源占用

功耗截图

Resource	Utilization	Available	Utilization %
LUT	92722	1182240	7.84
FF	46307	2364480	1.96
IO	187	832	22.48

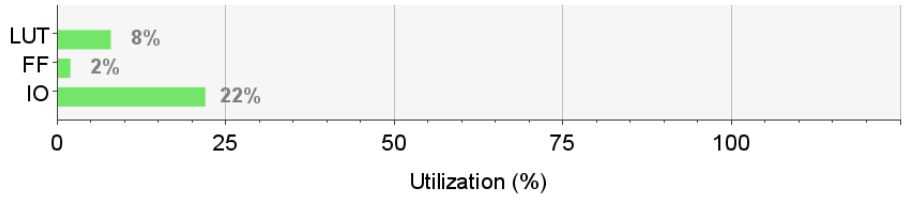

Power analysis from Implemented netlist. Activity derived from constraints files, simulation files or vectorless analysis.

Total On-Chip Power:	**3.663 W**
Design Power Budget:	**Not Specified**
Process:	typical
Power Budget Margin:	**N/A**
Junction Temperature:	**27.0°C**
Thermal Margin:	73.0°C (125.4 W)
Ambient Temperature:	25.0 °C
Effective ϑJA:	0.5°C/W
Power supplied to off-chip devices:	0 W
Confidence level:	Low

Launch Power Constraint Advisor to find and fix invalid switching activity

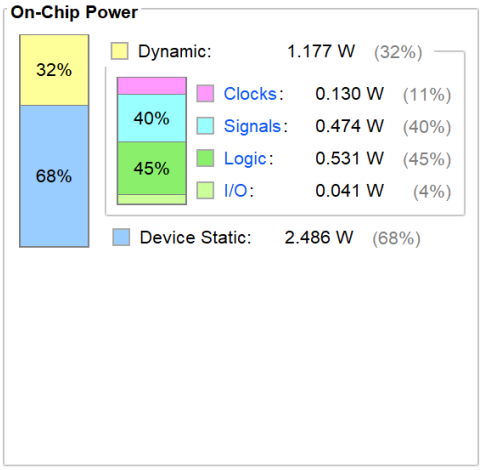

Timing **Setup** | Hold | Pulse Width

Worst Negative Slack (WNS):	0.34 ns
Total Negative Slack (TNS):	0 ns
Number of Failing Endpoints:	0
Total Number of Endpoints:	35927

Implemented Timing Report

四、项目不足及改进方向

时序裕度余量较少，可能不能稳定工作在 200M 时钟频率下。未来我们将把工作中心放在优化时序性能以及提升能效比上，以及做上板实物验证测试。